# 데이터 처리 및 분석 이론과 실습

2021.11

# 목 차

# 0. 개발 환경 구축

❖ 개인 PC에 설치

- Anaconda3 + VS Code 추천
- VS Code에서 Jupyter Notebook 사용

❖ Cloud 활용

- Google Colab 활용
- 크롬 브라우저와 Google ID만 있으면 어디에서든 접속 가능
- 인공지능, 데이터분석에 사용되는 대부분의 모듈(라이브러리)은 이미 설치되어 있음
- 한글 관련 모듈은 접속할 때 마다 설치해 주어야 함
- GPU, TPU 등을 무상으로 사용할 수 있음
- 한글 폰트 설치 및 브라우저 설정
  - D2 Coding 글꼴 설치 (https://github.com/naver/d2codingfont)
  - 크롬 브라우저 설정 > 글꼴 맞춤설정 > 고정폭 글꼴 > D2Coding
  - 크롬 브라우저 설정 > 고급 > 다운로드 전에 각 파일의 저장위치 확인 Check

# 0. 개발 환경 구축

- Colab 설정
  - 도구 > 설정 > 편집기

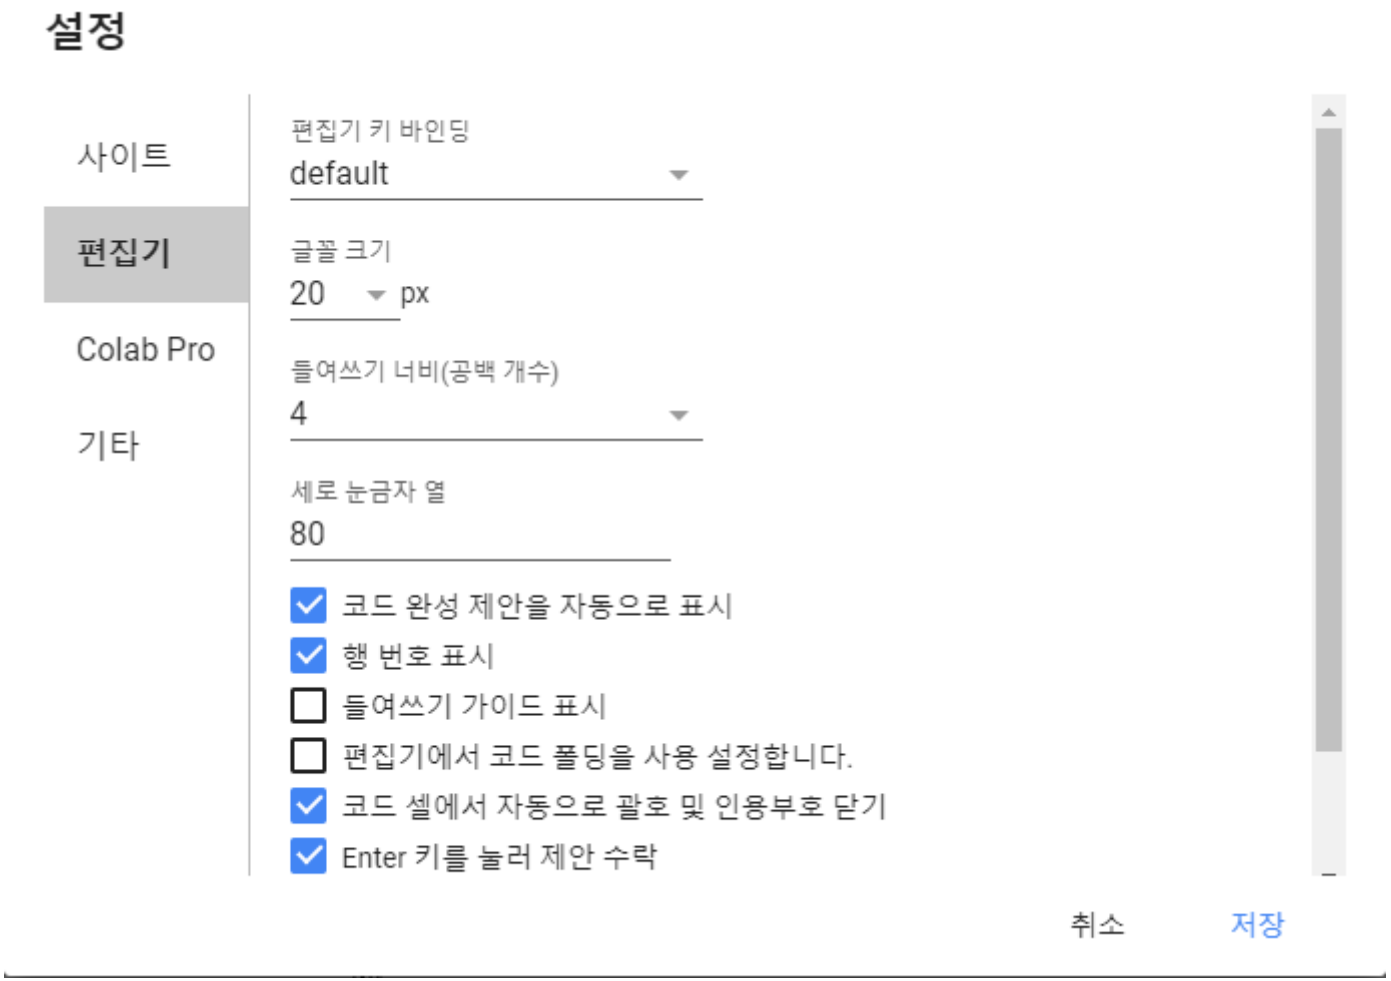

# 1. Numpy

## ❖ 넘파이란?

- 파이썬 과학 처리 패키지
  - Numerical Python
  - 파이썬의 고성능 과학 계산용 패키지
  - Matrix와 Vector와 같은 Array 연산의 사실상의 표준
- 특징
  - 일반 List에 비해 빠르고, 메모리를 효율적으로 사용
  - 반복문 없이 데이터 배열에 대한 처리를 지원함
  - 선형대수와 관련된 다양한 기능을 제공함
  - C, C++ 등의 언어와 통합 가능
- References
  - https://docs.scipy.org/doc/numpy/user/quickstart.html
  - 데이터 사이언스 스쿨 (데이터 과학을 위한 파이썬 기초)
    https://datascienceschool.net/view-notebook/39569f0132044097a15943bd8f440ca5
  - Numpy 강좌 https://www.youtube.com/playlist?list=PLBHVuYlKEkULZLnKLzRq1CnNBOBlBTkqp

# 1. Numpy

## ❖ ndarray(Numpy Dimensional Array)

- import

```
import numpy as np     # 표준화되어 있음
```

- Array 생성

```
test_array = np.array([1, 4, 5, 8], float)
print(test_array)
type(test_array[3])
print(test_array.dtype)   # Array 전체의 데이터 타입을 반환함
print(test_arry.shape)     # Array의 shape(차원 구성)을 반환함
```

- numpy는 np.array 함수를 활용하여 배열을 생성함 → ndarray
- numpy는 하나의 데이터 타입만 배열에 넣을 수 있음
- List와 가장 큰 차이점, Dynamic typing(예, [1, 2, "5", 4.2]) not supported
- C의 Array를 사용하여 배열을 생성함

## ❖ Array shape

- Vector (1차원)

```
test_array = np.array([1, 4, 5, 8], float)
```

➔ shape은 (4, ) : 1차원에 4개의 element가 있는 벡터

- Matrix (2차원)

```
matrix = [[1,2,5,8], [2,3,4,9], [4,5,6,7]]
np.array(matrix, int).shape
```

➔ shape은 (3, 4) : 행이 3개, 열이 4개인 매트릭스

- Tensor (3차원)

```
tensor = [[[1,2,5,8], [2,3,4,9], [4,5,6,7]],
          [[1,2,5,8], [2,3,4,9], [4,5,6,7]],
          [[1,2,5,8], [2,3,4,9], [4,5,6,7]],
          [[1,2,5,8], [2,3,4,9], [4,5,6,7]]]
np.array(tensor, int).shape
```

➔ shape은 (4, 3, 4) : 평면이 4개, 행이 3개, 열이 4개인 텐서

## ❖ Array shape

- ndim & size

```
np.array(tensor, int).ndim    # 3, number of dimension
np.array(tensor, int).size    # 48
```

- dtype

```
np.array([[1, 2, 3], [4.5, '5', '6']], dtype=np.float32)
array([[1. , 2. , 3. ],
       [4.5, 5. , 6. ]], dtype=float32)
```

  - Single element가 가지는 데이터 타입
  - C의 데이터 타입과 호환
  - nbytes – ndarray object의 메모리 크기를 바이트 단위로 반환함

- reshape
  - Array의 shape을 변경함 (element의 개수는 동일)

## ❖ Array shape

- reshape

```
test_matrix = [[1,2,3,4], [5,6,7,8]]
np.array(test_matrix).shape  ➔  (2, 4)
np.array(test_matrix).reshape(8, )  ➔  array([1,2,3,4,5,6,7,8])
np.array(test_matrix).reshape(8, ).shape  ➔  (8, )
```

  - Array의 shape을 변경함 (element의 개수는 동일)
  - Array의 size만 같다면 다차원으로 자유로이 변형가능

```
np.array(test_matrix).reshape(2, 4).shape  ➔  (2, 4)
np.array(test_matrix).reshape(-1, 2).shape  ➔  (4, 2)
                                  -1: size를 기반으로 row 개수 선정
np.array(test_matrix).reshape(2, 2, 2).shape  ➔  (2, 2, 2)
```

- flatten

```
test_matrix = [[[1,2,3,4], [5,6,7,8]], [[2,3,4,5], [6,7,8,9]]]
np.array(test_matrix).flatten()
➔ array([1,2,3,4,5,6,7,8,2,3,4,5,6,7,8,9])
```

  - 다차원 array를 1차원 array로 변환

## ❖ Indexing & slicing

- Indexing

```
a = np.array([[1,2,3], [4,5,6]], int)
print(a)
print(a[0,0])   # 2차원 배열 표기법 1
print(a[0][0])  # 2차원 배열 표기법 2
a[0, 0] = 1
```

  - List와 달리 이차원 배열에서 [0, 0]과 같은 표기법을 제공함
  - Matrix일 경우 앞은 행(row) 뒤는 열(column)을 의미함

- Slicing

```
a = np.array([[1,2,3,4,5], [6,7,8,9,10]], int)
a[:, 2:]     # 전체 row의 2열 이상
a[1, 1:3]    # row 1의 1~2열
a[1:3]               # 1 row ~ 2 row 전체, column은 무시
a[:, ::2]    # step 가능
```

  - List와 달리 행과 열 부분을 나눠서 slicing이 가능함
  - Matrix의 부분 집합을 추출할 때 유용함

## ❖ Creation function

- arange

```
np.arange(10) # arange – List의 range와 같은 효과
➔ array([0, 1, 2, 3, 4, 5, 6, 7, 8, 9])
np.arange(0, 5, 0.5)  # floating point도 표시가능
➔ array([0. , 0.5, 1. , 1.5, 2. , 2.5, 3. , 3.5, 4. , 4.5])
np.arange(0, 5, 0.5).tolist()  # List로 만들 수 있음
np.arange(30).reshape(5, 6)    # size가 같으면 가능

np.arrange(-2, 2.01, 0.02)              # 201개의 원소
np.linspace(-2, 2, 201)                 # 201개의 원소
```

- ones, zeros and empty

```
np.zeros(shape=(10,), dtype=np.int8)    # 원소가 10개인 벡터 생성
➔ array([0, 0, 0, 0, 0, 0, 0, 0, 0, 0], dtype=int8)
np.ones((2, 5))        # 2 x 5 – 값이 1인 matrix 생성
➔ array([1., 1., 1., 1., 1.],
        [1., 1., 1., 1., 1.]])
np.empty((3, 5))       # 메모리가 초기화되어 있지 않음
```

  - empty – shape만 주어지고 비어있는 ndarray 생성

## ❖ Creation function

- identity (단위 행렬 생성)

```
np.identity(n=3, dtype=np.int8)          # n → number of rows
➔ array([1, 0, 0],
        [0, 1, 0],
        [0, 0, 1]], dtype=int8)

np.identity(5)
➔ array([1., 0., 0., 0., 0.],
        [0., 1., 0., 0., 0.],
        [0., 0., 1., 0., 0.],
        [0., 0., 0., 1., 0.],
        [0., 0., 0., 0., 1.]])
```

- eye (대각선이 1인 행렬)

```
np.eye(N=3, M=5, dtype=np.int8)
➔ array([[1, 0, 0, 0, 0],
         [0, 1, 0, 0, 0],
         [0, 0, 1, 0, 0]], dtype=int8)
```

## ❖ Creation function

- Random sampling(데이터 분포에 따른 sampling으로 array를 생성)

```
np.random.seed(seed=1000)                    # 시드로 난수 생성 초기값 지정

np.random.uniform(0, 1, 10).reshape(2,5) # 균등 분포
                  최소 최대 개수
np.random.rand(10)

np.random.normal(0, 1, 10).reshape(2,5)  # 정규 분포
                 평균 표준편차 개수
np.random.randn(10)

np.random.binomial(n, p, size)           # 이항 분포
np.random.standard_t(df, size)           # t-분포
```

## ❖ Operation function

- Sum

```
test_array = np.arange(1,11)
test_array.sum(dtype=np.float)  ➔  55.0
```

- Axis
  - 모든 operation function을 실행할 때, 기준이 되는 dimension 축

```
test_array = np.arange(1,13).reshape(3,4)
➔ array([1, 2, 3, 4],
        [5, 6, 7, 8],
        [9,10,11,12]])

test_array.sum(axis=1)
➔ array([10, 26, 42])

test_array.sum(axis=0)
➔ array([15, 18, 21, 24])
```

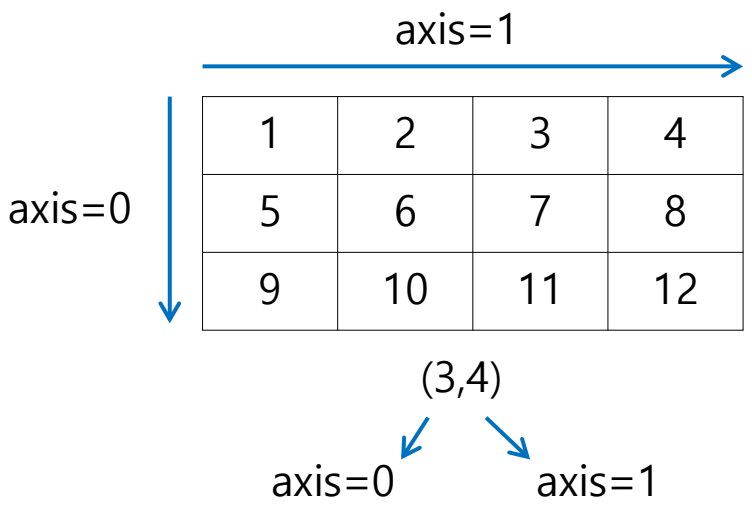

## ❖ Operation function

- Sorting

```
test_array = np.array([[4,3,5,7],[1,12,11,9],[2,5,1,14]])
np.sort(test_array)    # axis=1

np.sort(test_array, axis=0)

test_array.sort(axis=1)          # in-place method

a = np.array([42,38,12,25])
indices = np.argsort(a)          # 순서만 알고 싶을 때
a[indices]

a[indices][::-1]                 # 내림차순
```

- Mathematical functions

```
지수 함수: exp, expml, exp2, log, log10, loglp, log2, power, sqrt
삼각 함수: sin, cos, tan, arcsin, arccos, arctan
Hyperbolic: sinh, cosh, tanh, arcsinh, arccosh, arctanh

np.exp(test_array)
np.sqrt(test_array)
```

## ❖ Operation function

- Concatenate (Numpy array를 합치는 함수)

```
a = np.array([[1, 2], [3, 4]])
b = np.array([[5, 6]])
np.vstack((a,b))
➔ array([[1, 2],
         [3, 4],
         [5, 6]])
np.concatenate((a,b), axis=0)  # 위의 결과와 동일

a = np.array([[1], [2], [3]])
b = np.array([[2], [3], [4]])
np.hstack((a,b))
➔ array([[1, 2],
         [2, 3],
         [3, 4]])

a = np.array([[1, 2], [3, 4]])
b = np.array([[5, 6]])
np.concatenate((a, b.T), axis=1)                    # T - Transpose
➔ array([[1, 2, 5],
         [3, 4, 6]])
```

## ❖ Array operation

- Operations btw arrays (기본적인 사칙 연산 지원)

```
test_a = np.array([[1,2,3], [4,5,6]], float)
test_a + test_a
➔ array([2., 4., 6.],
        [8., 10., 12.]])
```

- Dot product

```
test_a = np.arange(1,7).reshape(2,3)     # Matrix 곱셈
test_b = np.arange(7,13).reshape(3,2)    # (l,m) x (m,n) → (l,n)
test_a.dot(test_b)
➔ array([ 58,  64],
        [139, 154]])
```

- Transpose

```
test_a = np.arange(1,7).reshape(2,3)
test_a.transpose()
test_a.T
```

- Broadcasting (Shape이 다른 배열간 연산 지원)

```
test_a + 3
```

## ❖ Comparison

- All & Any

```
a = np.arange(10)
➔ array([0, 1, 2, 3, 4, 5, 6, 7, 8, 9])

np.any(a>5)  ➔  True  # any – 하나라도 조건에 만족하면 True
np.any(a<0)  ➔  False

np.all(a>5)  ➔  False # all – 모두가 조건을 만족해야 True
np.all(a<10) ➔  True

a > 5
➔ array([False, False, False, False, False, False, True, True, True, True], dtype=bool)
```

- Logical operation

```
a = np.array([1, 3, 0], float)
b = np.logical_and(a>0, a<3)    # and 조건
➔ array([True, False, False], dtype=bool)

c = np.logical_not(b)
➔ array([False, True, True], dtype=bool)
np.logical_or(b,c)
➔ array([True, True, False], dtype=bool)
```

## ❖ Comparison

- argmax & argmin (array내 최대값 또는 최소값의 index를 리턴)

```
a = np.array([1,2,4,5,8,78,23,3])
np.argmax(a), np.argmin(a)
➔ (5, 0)

a = np.array([[1,2,4,7],[9,88,6,45],[8,78,23,3]])
np.argmax(a, axis=1)
➔ array([3, 1, 1])
np.argmax(a, axis=0)
➔ array([1, 1, 2, 1])

np.argmin(a, axis=1)
➔ array([0, 2, 3])
np.argmin(a, axis=0)
➔ array([0, 0, 0, 2])
```

| | | | |
|---|---|---|---|
| 1 | 2 | 4 | 7 |
| 9 | 88 | 6 | 45 |
| 8 | 78 | 23 | 3 |

## ❖ Boolean & fancy index

- Boolean index

```
test_array = np.array([1,4,0,2,3,8,9,7], float)
test_array > 3
➔ array([False, True, False, False, False, True, True, True],
          dtype=bool)

test_array[test_array > 3]   # 조건이 True인 index의 element만 추출
➔ array([4., 8., 9., 7.])
```

- Fancy index

```
a = np.array([2, 4, 6, 8], float)
b = np.array([0, 0, 1, 3, 2, 1], int)    # 반드시 integer로 선언

a[b]                    # b 배열의 값을 인덱스로 하여 a의 값들을 추출함
➔ array([2., 2., 4., 8., 6., 4.])      # bracket index

a.take(b)    # take 함수: bracket index와 같은 효과
```

## ❖ 기술 통계

- 표본 평균 – np.mean()
- 표본 분산
  - np.var(x)  # 모분산, 분모가 N
  - np.var(x, ddof=1)  # 표본분산, 분모가 N-1
- 표본 표준편차 – np.std()
- 최대값, 최소값 – np.max(), np.min(x)
- 중앙값 – np.median()
- 사분위수(quartile)
  - np.percentile(x, 0)  # 최소값
  - np.percentile(x, 25)  # 1사분위 수
  - np.percentile(x, 50)  # 2사분위 수
  - np.percentile(x, 75)  # 3사분위 수
  - np.percentile(x, 100)  # 최대값

# 1. Numpy - 연습 문제

1. 넘파이를 사용하여 다음과 같은 행렬을 만드시오.

```
10 20 30 40
50 60 70 80
```

2. 다음 행렬과 같은 행렬이 있다.

```
m = np.array([[ 0,  1,  2,  3,  4],
              [ 5,  6,  7,  8,  9],
              [10, 11, 12, 13, 14]])
```

   1) 이 행렬에서 값 7 을 인덱싱한다.
   2) 이 행렬에서 값 14 을 인덱싱한다.
   3) 이 행렬에서 배열 [6, 7] 을 슬라이싱한다.
   4) 이 행렬에서 배열 [7, 12] 을 슬라이싱한다.
   5) 이 행렬에서 배열 [[3, 4], [8, 9]] 을 슬라이싱한다.

3. 2번의 행렬 m을 1차원 벡터 f 로 변환한 후 다음의 문제를 푸시오.
   1) 이 배열에서 3의 배수를 찾아라.
   2) 이 배열에서 4로 나누면 1이 남는 수를 찾아라.
   3) 이 배열에서 3으로 나누면 나누어지고 4로 나누면 1이 남는 수를 찾아라.

4. 값을 직접 입력하지 말고 우측의 행렬을 만드시오.

$$\begin{bmatrix} 2, & 1, & 0, & 0, & 0 \\ 3, & 2, & 1, & 0, & 0 \\ 0, & 3, & 2, & 1, & 0 \\ 0, & 0, & 3, & 2, & 1 \\ 0, & 0, & 0, & 3, & 2 \end{bmatrix}$$

# 1. Numpy - 연습 문제

5. 0에서 10까지 랜덤 실수값으로 이루어진 5 x 6 형태의 데이터 행렬을 만들고 이 데이터에 대해 다음과 같은 값을 구하시오.
   1) 전체의 최댓값
   2) 각 행의 합
   3) 각 행의 최댓값
   4) 각 열의 평균
   5) 각 열의 최솟값

6. 다음 배열은 첫번째 행(row)에 학번, 두번째 행에 영어 성적, 세번째 행에 수학 성적을 적은 배열이다. 영어 성적을 기준으로 각 열(column)을 재정렬하시오.

```
array([[  1,   2,   3,   4],
       [ 46,  99, 100,  71],
       [ 81,  59,  90, 100]])
```

7. 주사위를 100번 던지는 가상 실험을 파이썬으로 작성하고,
   던져서 나오는 숫자의 평균을 구하시오.

8. 가격이 10,000원인 주식이 있다. 이 주식의 일간 수익률(%)은 기댓값이 0%이고 표준편차가 1%인 표준 정규 분포를 따른다고 하자. 250일 동안의 주가를 무작위로 생성하시오.

# 목 차

# 2. Pandas

## ❖ Pandas란?

- 데이터 분석에  가장 많이 사용되는 파이썬 패키지
- 열과 행으로 구성된 테이블 형태의 데이터를 다루는 데 주로 사용
- Series 클래스와 DataFrame 클래스로 구성
- 사용하는 방법이 매우 다양하고 어려워 데이터 분석을 하는 동안 계속 배워나가는 패키지

- References
  - API 문서 - https://pandas.pydata.org/docs/reference/index.html
  - Cheat Sheet - https://pandas.pydata.org/Pandas_Cheat_Sheet.pdf
  - 데이터 사이언스 스쿨 - https://datascienceschool.net/intro.html

## ❖ Series Class

- Numpy 1차원 배열 + 데이터의 의미를 표시하는 인덱스
- DataFrame의 하나의 열

- Series 생성

```
s = pd.Series([9904312, 3448737, 2890451, 2466052],
              index=["서울", "부산", "인천", "대구"])
```

- Series 인덱싱

```
s[1], s["부산"]       # Single value
s[[0, 3, 1]] # Series
```

- Series 연산

```
s / 1000000
```

## ❖ Series Class

- 시리즈와 딕셔너리 자료형

```
for key, value in s.items():
    print(f"{key}: {value}명")
```

- 인덱스 기반 연산

```
s2 = pd.Series({"서울":9631482,"부산":3393191,"인천":2632035,"대전":1490158},
                index=["부산", "서울", "인천", "대전"])
ds = s - s2
```

- 속성과 메소드

```
s.values, s.index
s.count()                          # 데이터 갯수 세기(NaN은 제외)
s.value_counts()                   # 카테고리 값 세기
s.unique(), s.nunique()            # 카테고리 이름, 갯수
s.sum(), s.mean()                  # 합계, 평균
s.sort_values(), s.sort_index()
```

## ❖ DataFrame Class 생성

- 2차원 데이터 + 행 인덱스 + 열 인덱스

- 기본이 되는 생성 방법
  - 우선 하나의 열이 되는 데이터를 리스트나 일차원 배열로 준비한다.
  - 이 각각의 열에 대한 이름(라벨)을 키로 가지는 딕셔너리를 만든다.
  - 이 데이터를 DataFrame 클래스 생성자에 넣는다.
  - 동시에 열방향 인덱스는 columns 인수로, 행방향 인덱스는 index 인수로 지정한다.

```
data = {
    "국어": [80, 90, 70, 30],
    "영어": [90, 70, 60, 40],
    "수학": [90, 60, 80, 70]
}
columns = ["국어", "영어", "수학"]                # 생략 가능
index = ["춘향", "몽룡", "향단", "방자"]

df = pd.DataFrame(data, index=index, columns=columns)
```

## ❖ DataFrame 파일 입출력

- 지원하는 파일 형식

  CSV, Excel, JSON, SAS, SQL 등

- 한글 인코딩에 주의
  - EUC-KR(CP949): 국가 표준, MS-Windows, 2바이트 완성형
  - UTF-8: Web, 대부분의 프로그램에서 사용하는 코드, 초성+중성+종성의 조합형

- CSV 파일 입력

```
%%writefile sample1.csv
c1,c2,c3
1,1.11,one
2,2.22,two
3,3.33,three

pd.read_csv('sample1.csv')
```

- CSV 파일 출력

```
df.to_csv('sample2.tsv', sep='\t', index=False)
```

## ❖ DataFrame 인덱싱

- 리스트나 배열 인덱싱과는 다르게 열을 먼저 선택하고 행을 선택함

```
df['c1'][0]          # 1
df.c1[0]             # 열의 명칭을 바로 쓸 수 있음. (JS의 Object 스타일)
df['c1']             # 시리즈
df[['c1', 'c3']]     # 데이터프레임
```

- loc 인덱서 - [행인덱스, 열인덱스]

```
df.loc[1,'c2']       # 2.22
df.loc[1]            # 시리즈
```

- iloc 인덱서 - [숫자 행인덱스, 숫자 열인덱스]

```
df.iloc[1, 1]        # 2.22
df.iloc[:2, 1:]      # 슬라이싱 가능
```

## ❖ DataFrame 데이터 조작

- 탐색하기 위한 메소드

```
head(), tail()                  # 앞/뒤의 5줄 보여주기
info()                          # 열의 정보
describe()                      # 요약 통계량
```

- sum 메소드

```
np.random.seed(1)
df2 = pd.DataFrame(np.random.randint(10, size=(4, 8)))
df2.sum(axis=1)                         # 행 합계
df2.sum() 또는 df2.sum(axis=0)          # 열 합계
```

- mean 메소드 - 결과는 실수로

```
df2.mean(axis=1)                        # 행 평균
df2.mean() 또는 df2.mean(axis=0)        # 열 평균
```

## ❖ DataFrame 데이터 조작

- 결측치 처리

```
import seaborn as sns
dt = sns.load_dataset('titanic')

dt.info()              # Null 데이터가 있는지 확인
dt.isnull().sum()      # 0이 아니면 Null(Na) 데이터가 있는 것임

dt.age.fillna(dt.age.mean(), inplace=True)
```

age열의 결측치를 age 열의 평균으로 대체

데이터프레임 dt의 데이터를 변경함

```
dt.dropna(subset=['embarked'], inplace=True)      # 행 삭제
dt.dropna(axis=1, inplace=True)                   # 널값이 있는 모든 열 삭제
dt.drop(columns=['deck'], inplace=True)           # 특정한 열 삭제
```

- astype 메소드 - 데이터 타입을 변경

## ❖ DataFrame 데이터 조작

- apply 메소드 - 행이나 열 단위로 더 복잡한 처리를 할 경우

```
df3 = pd.DataFrame({
    'A': [1, 3, 4, 3, 4],
    'B': [2, 3, 1, 2, 3],
    'C': [1, 5, 2, 4, 4]
})

# 각 열의 최대값과 최소값의 차이를 구하고 싶을 때
df3.apply(lambda x: x.max() - x.min())
df3.apply(lambda x: x.max() - x.min(), axis=1)   # 행에 대해 적용


# 타이타닉호의 승객 중 나이 20살을 기준으로 성인(adult)과 미성년자(child)를
# 구별하는 라벨 열을 만들 때

titanic["adult/child"] =
    titanic.apply(lambda r: "adult" if r.age >= 20 else "child", axis=1)
```

## ❖ DataFrame 데이터 조작 - 문자열 관련 메소드 (.str 이 앞에 붙음)

- 실습 데이터 준비(행정표준관리시스템: https://www.code.go.kr/index.do)

```
from google.colab import files
uploaded = files.upload()
filename = list(uploaded.keys())[0]

df = pd.read_csv(filename, sep='\t', encoding='euc-kr')
df = df[df.폐지여부 == '존재']
df.head()
```

- 인덱싱 : .str[]

```
df['법정동명'].str[:5].tail()  # 앞 5글자만 추출
```

- 찾기 : .str.find()

```
df['법정동명'].str.find('동').head()
```

- 분할 : .str.split()

```
df['법정동명'].str.split().head()       # 공백으로 분할
```

## ❖ DataFrame 데이터 조작 - 문자열 관련 메소드 (.str 이 앞에 붙음)

- 포함글자 인식 : .str.contains()

```
df[df['법정동명'].str.contains('강서구')].head() # 강서구 포함 법정동 추출
```

- 문자 대체 : .str.replace()

```
# 스트링 메소드와는 달리 정규 표현식을 사용할 수 있음
df['법정동명'].str.replace(' ', '_').head()      # 공백을 _로 대체
```

- 공백제거 : .str.strip()

```
df2 = pd.DataFrame({'c1': [' Abc ', ' xYz '], 'c2': [' abC ', ' xyZ ']})
df2.c1.str.strip()
```

- 소문자 변경: .str.lower()

```
df2.c2.str.lower()
df2.c2.apply(lambda x: x.lower())
```

## ❖ DataFrame 인덱스 조작

- set_index : 기존의 행 인덱스를 제거하고 데이터 열 중 하나를 인덱스로 설정

```
np.random.seed(2021)
data = np.vstack([list('ABCDE'), np.round(np.random.rand(3, 5), 2)])

df = pd.DataFrame(data.T, columns=['C1','C2','C3','C4'])
df2 = df.set_index("C1")                    # df는 변하지 않고, df2만 변함

df.set_index("C1", inplace=True)            # df 자체를 변하게 할 경우
df.index.name = 'Index'
```

- reset_index : 기존의 행 인덱스를 제거하고 인덱스를 데이터 열로 추가

```
df3 = df.reset_index()          # df는 변하지 않고, df3만 변함

df.reset_index(inplace=True)    # df 자체를 변하게 할 경우
df.rename(columns={'Index':'C1'}, inplace=True)
```

## ❖ DataFrame 합성

- merge 함수 : 두 데이터 프레임의 공통 열 혹은 인덱스를 기준으로 두 개의 테이블을 합침

```
df1 = pd.DataFrame({
    '고객번호': [1001, 1002, 1003, 1004, 1005, 1006, 1007],
    '이름': ['둘리', '도우너', '또치', '길동', '희동', '마이콜', '영희']
}, columns=['고객번호', '이름'])

df2 = pd.DataFrame({
    '고객번호': [1001, 1001, 1005, 1006, 1008, 1001],
    '금액': [10000, 20000, 15000, 5000, 100000, 30000]
}, columns=['고객번호', '금액'])

df3 = pd.merge(df1, df2)                          # Inner join

df4 = pd.merge(df1, df2, how='outer')    # Outer join
```

- join 메소드

```
df3 = df1.set_index('고객번호')
df4 = df2.set_index('고객번호')
df3.join(df4, how='inner')
```

## ❖ DataFrame 그룹 분석

- groupby 메소드
  - 분석하고자 하는 시리즈나 데이터프레임에 groupby 메서드를 호출하여 그룹화를 한다.
  - 그룹 객체에 대해 그룹연산을 수행한다.
- 그룹연산 메소드
  - size, count: 그룹 데이터의 갯수
  - mean, median, min, max: 그룹 데이터의 평균, 중앙값, 최소, 최대
  - sum, prod, std, var, quantile : 그룹 데이터의 합계, 곱, 표준편차, 분산, 사분위수
  - first, last: 그룹 데이터 중 가장 첫번째 데이터와 가장 나중 데이터

- 아이리스 각 품종별 피쳐의 평균은?

```
import seaborn as sns
iris = sns.load_dataset('iris')

iris.groupby('species').mean()
iris[['sepal_length','species']].groupby('species').std()
iris.groupby('species')['sepal_length'].std()
iris.groupby('species')['sepal_length'].agg(['mean','std','max','min'])
```

## ❖ DataFrame 그룹 분석

- tips 데이터

```
import seaborn as sns
tips = sns.load_dataset('tips')
tips['tip_pct'] = np.round(tips.tip / tips.total_bill * 100, 2)

tips.groupby('sex')[['tip_pct']].mean()
tips.groupby('smoker')[['tip_pct']].mean()

tips.groupby(['sex','smoker'])[['tip_pct']].mean()
tips.groupby(['sex','smoker','time'])[['tip_pct']].mean()
```

1) Iris - sns.load_dataset('iris')

a. 붓꽃 종(species)별로 꽃잎길이(sepal_length), 꽃잎폭(sepal_width), 꽃받침길이(petal_length), 꽃받침폭(petal_width)의 평균, 표준편차 등 기초통계량(describe())을 구하시오.

b. 3분위수(Q3)와 1분위수(Q1)의 차이보다 1.5배가 크거나 작은 데이터는 이상치이다.
즉,
Q1 - 1.5 * (Q3 - Q1) 보다 작은 데이터
Q3 + 1.5 * (Q3 - Q1) 보다 큰 데이터

이 이상치를 제거하고 위의 4가지 항목에 대해서 평균, 표준편차를 구하시오.

2) Titanic - sns.load_dataset('titanic')

a. 타이타닉호의 승객에 대해 나이와 성별에 의한 카테고리 열인 category1 열을 만드시오. category1 카테고리는 다음과 같이 정의됨

   1) 20살이 넘으면 성별을 그대로 사용한다.
   2) 20살 미만이면 성별에 관계없이 “child”라고 한다.

b. 타이타닉호의 승객 중 나이를 명시하지 않은 고객은 나이를 명시한 고객의 평균 나이 값이 되도록 titanic 데이터프레임을 고치시오.

c. 성별, 선실(class)별, 출발지(embark_town)별 생존율을 구하시오.

d. 타이타닉호 승객을 ‘미성년자’, ‘청년’, ‘중년’, ‘장년’, ‘노년’ 나이 그룹으로 나누고, 각 그룹별 생존율을 구하시오.

```
bins = [1, 20, 30, 50, 70, 100]
labels = ["미성년자", "청년", "중년", "장년", "노년"]
```

e. qcut 명령으로 세 개의 나이 그룹을 만들고, 나이 그룹별 남녀 성비와 생존율을 구하시오.

3) Mile Per Gallon - sns.load_dataset('mpg')

a. 배기량(displacement) 대비 마력(horsepower) 열(hp_per_cc)을 추가하시오.

b. name으로부터 manufacturer(제조사)와 모델을 추출하여
새로운 열 manufacturer와 model을 추가하고, name 열은 삭제하시오.

c. 엔진의 실린더(cylinders) 갯수별 연비(mpg)의 평균을 구하시오.

d. 생산지(origin)별 배기량 대비 마력(hp_per_cc)의 평균을 구하시오.

e. 모델이 5개 이상인 제조사에 대하여
연비(mpg)의 평균이 가장 좋은 제조사 Top 5를 구하시오.

# 목 차

# 3. Matplotlib

## ❖ Matplotlib 란?

- 개요
  - 파이썬에서 자료를 시각화(Visualization)해주는 패키지
  - Pandas 시리즈와 데이터프레임의 plot 메소드 활용
- 그릴 수 있는 Chart / Plot
  - 라인 플롯(line plot)
  - 산점도(scatter plot)
  - 막대 그래프(bar chart), 히스토그램(histogram)
  - 박스 플롯(box plot)
  - 파이 차트(pie chart)
  - 컨투어 플롯(contour plot), 서피스 플롯(surface plot) 등
- 참고 사이트
  - 갤러리(`http://matplotlib.org/gallery.html`)

## ❖ Matplotlib 란?

### ▪ 그래프 그려보기

- 모듈 임포트

```
import matplotlib.pyplot as plt
%matplotlib inline
```

- 라인 플롯

```
plt.title("Plot")
plt.plot([1, 4, 9, 16])         # y 값 리스트
plt.show()

plt.title("x ticks")
plt.plot([10, 20, 30, 40], [1, 4, 9, 16])         # x 값 리스트, y 값 리스트
plt.grid()
plt.show()
```

## ❖ 한글 설정

- Local 개발 환경

```
import matplotlib as mpl
import matplotlib.pyplot as plt
import matplotlib.font_manager as fm

mpl.rcParams['axes.unicode_minus'] = False   # minus 표시

[(f.name, f.fname) for f in fm.fontManager.ttflist if 'Malgun' in f.name]
[('Malgun Gothic', 'C:\\WINDOWS\\Fonts\\malgun.ttf'),
 ('Malgun Gothic', 'C:\\Windows\\Fonts\\malgun.ttf'),
 ('Malgun Gothic', 'C:\\Windows\\Fonts\\malgunsl.ttf'),
 ('Malgun Gothic', 'C:\\Windows\\Fonts\\malgunbd.ttf'),
 ('Malgun Gothic', 'C:\\WINDOWS\\Fonts\\malgunsl.ttf'),
 ('Malgun Gothic', 'C:\\WINDOWS\\Fonts\\malgunbd.ttf')]

plt.rcParams["font.family"] = 'Malgun Gothic‘

plt.title("X ticks를 사용한 플롯")
plt.plot([10, 20, 30, 40], [1, 4, 9, 16])
plt.grid()
plt.show()
```

## ❖ 한글 설정

- Colab 환경

```
!apt-get install -y fonts-nanum > /dev/null
!fc-cache -fv > /dev/null
!rm -rf ~/.cache/matplotlib > /dev/null

런타임 > 런타임 다시 시작

import matplotlib as mpl
import matplotlib.pyplot as plt
mpl.rcParams['axes.unicode_minus'] = False
plt.rc('font', family='NanumBarunGothic')

plt.title("X ticks를 사용한 플롯")
plt.plot([10, 20, 30, 40], [1, 4, 9, 16])
plt.grid()
plt.show()
```

## ❖ Line Plot

- 데이터가 시간, 순서 등에 따라 어떻게 변화하는지 보여주기 위해 사용
- Series 타입에서 value가 y축, index가 x축

```
x = [0, 1, 2, 3]
y = [0, 1, 4, 9]
plt.plot(x, y)
plt.show()

s = pd.Series(np.random.randn(10).cumsum(), index=np.arange(10))
plt.plot(s)                                  # s.plot()

plt.plot(s, color='g', marker='o', linestyle='-')
plt.plot(s, 'bs--')

plt.plot(s, 'r*:', lw=3, ms=10)              # linewidth, markersize

color: blue, green, red, cyan, magenta, yellow, black(k), white
marker: circle(o), 삼각형(^), 역삼각형(v), 사각형(s), 별(*), 플러스(+)
linestyle: 직선(-), dashed(--), dash-dot(-.), dotted(:)
```

## ❖ 산점도(Scatter Plot)

- Anscombe's quartet: 기술 통계치가 거의 같은 4가지 데이터 셋
- x와 y의 관계를 눈으로 확인하고자 할 때

```
x = np.random.randn(100)
y = np.random.randn(100)
plt.scatter(x, y)
plt.show()

x = np.random.rand(100)
y = np.random.rand(100)
colors = np.random.rand(100)
area = np.pi * (15 * np.random.rand(100))**2
plt.scatter(x, y, label='Samples', s=area, c=colors, alpha=0.5)
        s: 도형의 크기(size)
        c: 도형의 색상(color)
        alpha: 투명도 (0-완전 투명, 1-완전 불투명)

x1 = np.random.normal(1, 1, size=(100, 1))
x2 = np.random.normal(-2, 4, size=(100, 1))
plt.scatter(x1, x2, color='r', marker='s')
```

## ❖ 막대 그래프(Bar chart), 히스토그램(histogram)

- 특정 그룹의 데이터의 추세와 정량적인 분포

```
import pandas as pd
s2 = pd.Series(np.random.rand(10), index=list('abcdefghij'))
plt.bar(s2.index, s2.values)              # s2.plot(kind='bar')
plt.show()


df2 = pd.DataFrame(np.random.rand(6, 4),
                   index = ['one', 'two', 'three', 'four', 'five', 'six'],
                   columns = pd.Index(['A','B','C','D'], name='Genus'))
df2.plot(kind='barh', figsize=(12,8))
df2.plot(kind='barh', stacked=True)

s3 = pd.Series(np.random.randn(200))
plt.hist(s3)                        # s3.hist()

plt.hist(s3, bins=50)  # default는 10

plt.hist(s3, bins=100, normed=True)
```

## ❖ 박스 플롯(Box plot)

- 기초 통계량 확인하고자 할 때

```
s4 = np.random.randn(1000)
s5 = np.random.normal(loc=10, scale=2, size=1000)
plt.boxplot([s4, s5])
```

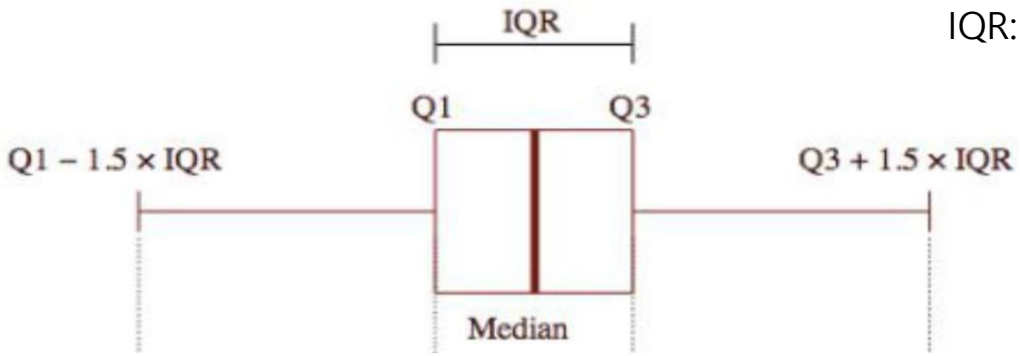


IQR: Inter Quartile Range

```
# Setosa 품종
setosa = iris[iris.species == 'setosa']
plt.figure(figsize=(8,10))
plt.boxplot([setosa.sepal_length, setosa.sepal_width,
             setosa.petal_length, setosa.petal_width],
            labels=['sl','sw','pl','pw'])
plt.title('Setosa 품종의 각 피쳐', fontsize=15)
plt.show()
```

## ❖ 파이 차트(Pie Chart)

- 범주별 구성 비율을 원형으로 표현

```
ratio = [34, 32, 16, 18]
labels = ['Apple', 'Banana', 'Melon', 'Grapes']

plt.pie(ratio, labels=labels, autopct='%.1f%%')
plt.show()
```

## ❖ 이미지 보기(Imshow)

```
from PIL import Image
image = Image.open(filename)

plt.imshow(image)
plt.axis('off')
plt.show()
```

❖ 제목, 레이블, 범례 작성

```
import numpy as np
xs = np.linspace(0, 2*np.pi, 800)        # 0 ~ 2*pi 구간을 800 등분
ysin = np.sin(xs)
ycos = np.cos(xs)

plt.plot(xs, ysin, label='Sine curve')
plt.plot(xs, ycos, label='Cosine curve')
plt.xlim([-0.1, 2*np.pi+0.1])
plt.ylim([-1.2, 1.2])
plt.xlabel('X-Value'); plt.ylabel('Y-Value')
plt.title('삼각함수')
plt.legend()                             # label을 범례로 표시

for y_val in [-1, 0, 1]:
    plt.axhline(y=y_val, color='k', linewidth=0.5)        # 수평선
for x_val in np.arange(0, 2*np.pi+0.01, np.pi/2):
    plt.axvline(x=x_val, c='k', lw=0.5)                   # 수직선

plt.show()
plt.savefig('image.png')                 # image.png 로 저장
```

❖ 여러 개의 그래프를 그리는 방법(Subplot)

```
def f(t):
    return np.exp(-t) * np.cos(2*np.pi*t)

def g(t):
    return np.sin(np.pi*t)

t1 = np.arange(0.0, 5.0, 0.01)
t2 = np.arange(0.0, 5.0, 0.01)

plt.subplot(221)                # 2 x 2, 그래프중 첫번째
plt.plot(t1, f(t1))
plt.subplot(2, 2, 2)
plt.plot(t2, g(t2))

plt.subplot(223)
plt.plot(t1, f(t1), 'r-')
plt.subplot(224)
plt.plot(t2, g(t2), 'r-')

plt.show()
```

## ❖ 여러 개의 그래프를 그리는 방법

- Anscombe's Quartet

```
import seaborn as sns
ans = sns.load_dataset('anscombe')

fig, axes = plt.subplots(2, 2, figsize=(10,8),
                         sharex=True, sharey=True)
for index, roman in enumerate(['I','II','III','IV']):
    ds = ans[ans.dataset == roman]
    ax = axes[index//2, index%2]
    ax.plot(ds.x, ds.y, 'o', markersize=10)
    ax.plot([3, 20], [4.5, 13], 'r-', lw=2) # y = 0.5 * x + 3
    ax.set_title(f'Dataset {roman}')

fig.suptitle("Anscombe's Quartet", fontsize=16)
plt.tight_layout()
plt.show()
```

## ❖ Pandas 시각화

- plot 메소드

```
np.random.seed(0)
df1 = pd.DataFrame(np.random.randn(100, 3),
                   index=pd.date_range('1/1/2021', periods=100),
                   columns=['A', 'B', 'C']).cumsum()
df1.plot()
plt.title("Pandas의 Plot메소드 사용 예")
plt.xlabel("시간")
plt.ylabel("Data")
plt.show()
```

- 다양한 plot
  - kind 인수값 설정
  - bar, pie, hist, kde, box, scatter, area 등
  - plot.bar 와 같이 직접 메소드로 이용도 가능

## ❖ Pandas 시각화

- 다양한 플롯 예

```
iris = sns.load_dataset("iris")    # 붓꽃 데이터
titanic = sns.load_dataset("titanic")    # 타이타닉호 데이터

df2 = iris.groupby(iris.species).mean()
df2.columns.name = "feature"
df2.plot(kind='bar', rot=0)
plt.title("각 종의 Feature별 평균")
plt.xlabel("평균"); plt.ylabel("종"); plt.ylim(0, 8)
plt.show()

df3 = titanic.pclass.value_counts()
df3.plot.pie(autopct='%.2f%%')
plt.title("선실별 승객 수 비율")
plt.axis('equal')
plt.show()
```

## ❖ 다른 시각화 패키지 - Seaborn

- 세련된 그래프
- https://seaborn.pydata.org/examples/index.html

```
import matplotlib.pyplot as plt
import seaborn as sns

titanic = sns.load_dataset("titanic")
sns.countplot(x="class", data=titanic)
plt.title("타이타닉호의 각 클래스별, 승객 수")
plt.show()

iris = sns.load_dataset("iris")
sns.pairplot(iris)
plt.title("Iris Data의 Pair Plot")
plt.show()

tips = sns.load_dataset('tips')
sns.boxplot(x="day", y="total_bill", data=tips)            # hue='sex'
plt.title("요일 별 전체 팁의 Box Plot")
plt.show()
```

## ❖ 다른 시각화 패키지 - Folium

- 지도위에 위치정보를 시각화, 웹에서 사용 가능

```
import folium

map = folium.Map(location=[37.559868, 126.967109], zoom_start=14)
folium.Marker(
    location=[37.559868, 126.967109], popup='한국경제신문사'
).add_to(map)
folium.Marker(
    location=[37.566317, 126.977829],
    tooltip='서울특별시청',
    icon=folium.Icon(color="red", icon="info-sign")
).add_to(map)
folium.Circle(
    location=[37.56412, 126.998009],
    radius=100, tooltip='중구청',
    color='crimson', fill=False
).add_to(map)

title_html = '<h3 align="center" style="font-size:20px">3개 지역 표시</h3>'
map.get_root().html.add_child(folium.Element(title_html))

map
```

# 목 차

# 4. 데이터 분석 사례 - 서울시 구별 CCTV 현황 분석

## ❖ 필요 데이터

- 서울 열린데이터 광장(https://data.seoul.go.kr/index.do)
  - 자치구 년도별 CCTV 설치 현황
  - 서울통계서비스 > 주민등록인구(구별) 통계

## ❖ CCTV 데이터 정리하기

- 데이터 파일 읽기

```
cctv = pd.read_csv(filename, skiprows=1, encoding='euc-kr')
```

```
구분  총계  2012년 이전  2012년  2013년  2014년  2015년  2016년  2017년  2018년  2019년  2020년  2021년
```

- Null data 있는지 확인하기

```
cctv.isnull().sum().sum()
```

- 1000 단위 구분기호 없애고 정수로 변환하기

```
for column in cctv.columns[1:]:
    cctv[column] = cctv[column].apply(lambda x: int(x.replace(',','')))
```

## ❖ CCTV 데이터 정리하기

- 2021년을 제외한 최근 3개년간의 CCTV 증가율 구하기

```
cctv['2017년_이전'] = cctv.총계 - cctv['2018년'] - cctv['2019년'] \
                      - cctv['2020년'] - cctv['2021년']

cctv['최근증가율'] = ((cctv['2018년']+cctv['2019년']+cctv['2020년']) / \
                      cctv['2017년_이전'] * 100).round(2)
```

- 구분, 총계, 최근증가율 컬럼만 추출하고 컬럼명을 구별, CCTV댓수로 변경하기

```
cctv = cctv[['구분', '총계','최근증가율']]
cctv.rename(columns={'구분':'구별', '총계':'CCTV댓수'}, inplace=True)
```

- 구 이름에서 공백지우기

```
cctv['구별'] = cctv.구별.apply(lambda x: x.replace(' ',''))
```

- 첫번째 행 지우기

```
cctv.drop([0], inplace=True)
```

## ❖ 인구 데이터 정리하기

- 데이터 파일 읽기

```
pop = pd.read_csv(filename, sep='\t', skiprows=2)
```

```
기간  자치구  세대  계  남자  여자  계.1  남자.1  여자.1  계.2  남자.2  여자.2  세대당인구  65세이상고령자
```

- Null data 있는지 확인하기

```
pop.isnull().sum().sum()
```

- '자치구','계','계.1','계.2','65세이상고령자' 컬럼만 추출하고 이름을 변경

```
pop = pop[['자치구','계','계.1','계.2','65세이상고령자']]
pop.columns = ['구별','인구수','내국인','외국인','고령자']
```

- 1000 단위 구분기호 없애고 정수로 변환하기

```
for column in pop.columns[1:]:
    pop[column] = pop[column].apply(lambda x: int(x.replace(',','')))
```

- 첫번째 행 지우기

```
pop.drop([0], inplace=True)
```

## ❖ 인구 데이터 정리하기

- '외국인비율'과 '고령자비율' 컬럼 만들기

```
pop['외국인비율'] = (pop.외국인/pop.인구수*100).round(2)
pop['고령자비율'] = np.round(pop.고령자/pop.인구수*100, 2)
```

```
구별   인구수   내국인   외국인   고령자   외국인비율   고령자비율
```

## ❖ CCTV 데이터와 인구 데이터 합치기

- 데이터 합치기

```
df = pd.merge(cctv, pop)
```

- '구별' 컬럼을 인덱스로 만들기

```
df.set_index('구별', inplace=True)
```

## ❖ 상관관계 분석하기

- 'CCTV댓수' vs '고령자비율', '외국인비율', '인구수'

```
fig, axs = plt.subplots(figsize=(15,5), ncols=3, nrows=1)
features = ['고령자비율','외국인비율','인구수']
for i, feature in enumerate(features):
    sns.regplot(x=feature, y='CCTV댓수', data=df, ax=axs[i])
```

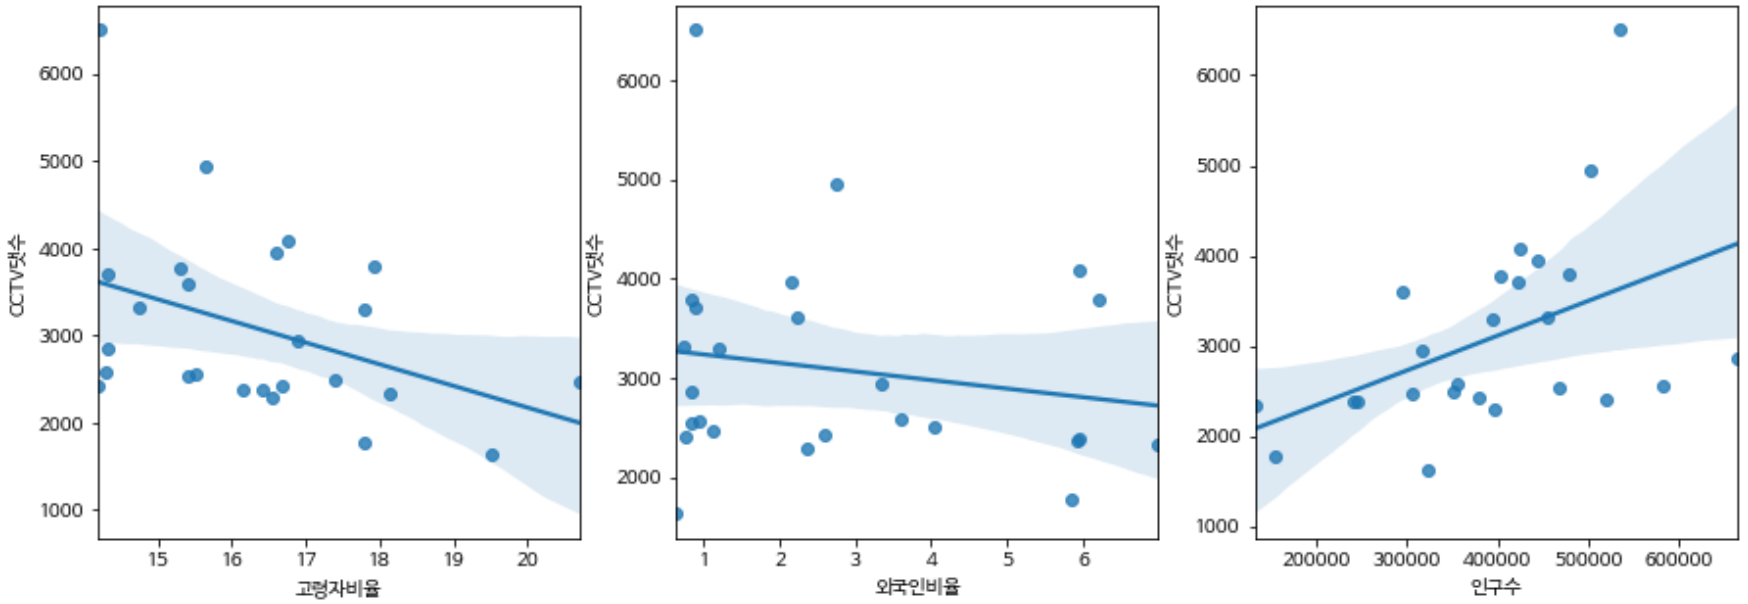

## ❖ 그래프 분석

### ▪ 구별 CCTV 댓수

```
df.CCTV댓수.sort_values().plot(kind='barh', grid=True, figsize=(12,8),
                                title='구별 CCTV 댓수')
plt.show()
```

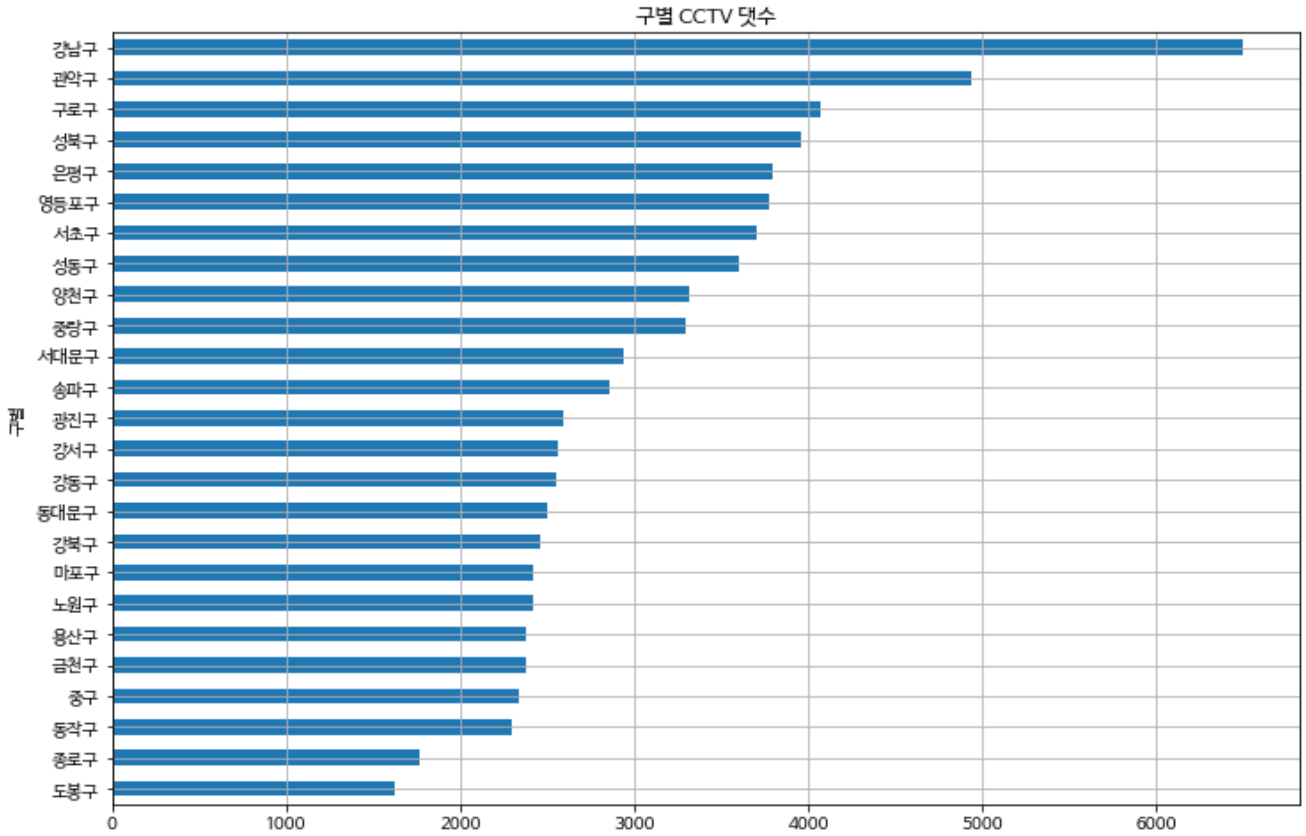

## ❖ 그래프 분석

### ▪ 인구대비 CCTV 비율

```
df['cctv비율'] = (df.CCTV댓수 / df.인구수 * 100).round(2)
df.cctv비율.sort_values().plot(kind='barh', grid=True, figsize=(12,8))
plt.title('인구대비 CCTV 비율')
plt.show()
```

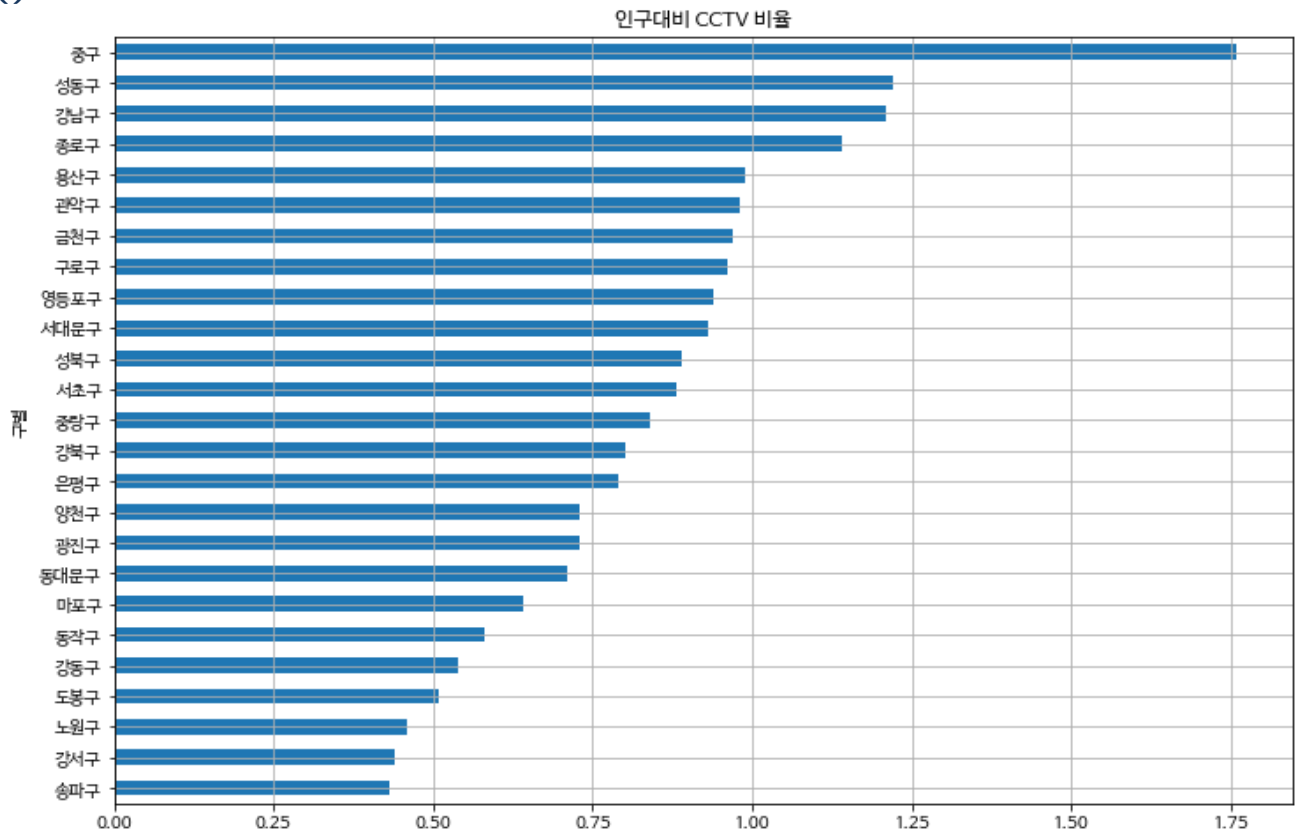

## ❖ 인구수와 CCTV 댓수 분석

- 산점도

```
plt.scatter(df.인구수, df.CCTV댓수, s=50)
plt.grid(True)
plt.title('인구수와 CCTV 댓수의 산점도')
plt.xlabel('인구수')
plt.ylabel('CCTV')
plt.show()
```

- 산점도 위에 상관관계를 나타내는 선

```
fp1 = np.polyfit(df.인구수, df.CCTV댓수, 1)      # 1은 함수의 차수
fx = np.array([100000, 700000])
f1 = np.poly1d(fp1)                              # 1차원의 회귀식
fy = f1(fx)
```

- 오차를 계산하고, 오차의 내림차순으로 소팅된 데이터프레임 만들기

```
df['오차'] = np.abs(df.CCTV댓수 - f1(df.인구수)).round(2)

df_sort = df.sort_values('오차', ascending=False)
```

## ❖ 인구수와 CCTV 댓수 분석

- 최종

```
plt.figure(figsize=(14,10))
plt.scatter(df.인구수, df.CCTV댓수, c=df.오차, s=50)
plt.plot(fx, fy, ls='dashed', lw=3, color='g')

for i in range(10):
    plt.text(df_sort.인구수[i]+9000, df_sort.CCTV댓수[i]-50,
             df_sort.index[i], fontsize=15)

plt.grid(True)
plt.title('인구수와 CCTV 댓수의 관계', fontsize=20)
plt.xlabel('인구수')
plt.ylabel('CCTV')
plt.colorbar()
plt.show()
```

## ❖ 인구수와 CCTV 댓수 분석

- 최종